

SCORING DE CRÉDIT ÉQUITABLE PAR OPTIMISATION SOUS CONTRAINTES

Intelligence Artificielle Finance
Projet 1

PRÉSENTÉE PAR
CHRISMANT Hugo
CLEMENT Jérémy
FAYE Mael

02/02/2026

Credit Scores



Problème & Objectif

- Les systèmes de scoring de crédit automatisés peuvent reproduire des biais
- différences de traitement selon le sexe, ethnie, situation géographique

Problématique :

Comment intégrer des contraintes d'équité dans un modèle de scoring de crédit tout en conservant des performances acceptables ?

Approche : Optimisation sous contraintes avec Fairlearn (Exponentiated Gradient Reduction)

Données & Variable Sensible

Pré-traitement :

- One-hot encoding des variables catégorielles
- Standardisation (StandardScaler)
- Split stratifié train/test (70/30)

Variable cible

DEFAULT (DE PAIEMENT)

(0 = non, 1 = oui)

**Attribut
sensible**

SEXE

(pour mesurer l'équité)

Features

Revenus, montant du crédit, durée, durée d'emploi, statut marital, statut du logement, personnes à charge, niveau d'éducation

Métriques (Performance + Équité)

Performance :

- Accuracy, AUC

Équité :

- **Demographic Parity (DP)** : écart de taux d'acceptation entre groupes
- **Equalized Odds (EO)** : écart de taux d'erreur (FPR/FNR) entre groupes

Solution n°3

Réduire DP et EO sans trop dégrader la précision



Méthodes Comparées

3 approches :

<i>Approche</i>	Description
Baseline	Régression logistique sans contrainte d'équité
In-processing (DP)	Fairlearn + Exponentiated Gradient + contrainte Demographic Parity
In-processing (EO)	Fairlearn + Exponentiated Gradient + contrainte Equalized Odds

Baseline – Résultats & Biais Observé

Performance


- Accuracy : **0.78**
- AUC : **0.90**

Biais observé

- DP diff : **0.35** (écart important)
- EO diff : **0.25**

Taux d'acceptation par groupe

- Groupe 0 : **75%**
- Groupe 1 : **40%**




Conclusion : Modèle performant mais discriminant


In-processing (Demographic Parity)

Principe : Contrainte DP via
Exponentiated Gradient ($\epsilon = 0.02$)

Résultats :



Taux d'acceptation par groupe :



Conclusion : Réduction efficace du biais DP mais dégradation de la précision

In-processing (Equalized Odds)

Principe : Contrainte EO via
Exponentiated Gradient ($\epsilon = 0.02$)

Résultats :

Accuracy

0.78 (identique à
baseline)

DP diff

0.35 (inchangé)

EO diff


0.25 (inchangé)

Conclusion : La contrainte EO n'a pas d'impact significatif sur ce dataset (limitation identifiée)

Trade-off Équité vs Performance

Analyse du sweep DP ($\epsilon = 0.005$ à 0.1) :

- Plus ϵ est petit $\rightarrow$ équité plus stricte
- Perte de performance progressive
- Sweet spot : $\epsilon \approx 0.02$ (bon compromis équité/performance)



Engineering & Delivery

Livrables :

- Code source documenté
- README avec installation et tests
- Documentation technique

Stack technique réelle

- Python, pandas, numpy, scikit-learn
- **Fairlearn** : ExponentiatedGradient, DemographicParity, EqualizedOdds
- **cvxpy** : optimisation convexe (utilisé par Fairlearn)
- matplotlib, seaborn : visualisation
- **SHAP** : explicabilité (module implémenté)

Organisation :

- Code modulaire : src/, notebooks/, docs/
- Tests unitaires : test_fairness_metrics.py, test_smoke.py
- Documentation : README + docs techniques

Conclusion

Limites

Perspectives

L'intégration de contraintes d'équité via Fairlearn permet de réduire significativement les biais (DP diff -57%) avec une perte de performance contrôlée.

- La contrainte EO n'a pas d'impact significatif sur ce dataset
- Trade-off équité/performance non linéaire
- Dataset synthétique de taille limitée

- Tester sur des données réelles bancaires
- Explorer d'autres contraintes (Counterfactual Fairness)
- Intégrer dimension coût/profit business
- Généraliser à plusieurs attributs sensibles